

Double Star Protocol

双子星协议

—— 基于卡巴拉生命之树的 AI 安全对齐系统

项目介绍与合作提案

Project Introduction & Collaboration Proposal

发起人：岳祥瑞 (Yue Xiangrui)

独立研究员 | 小说家 | 游戏开发者

2026 年 4 月

一、项目概述 (Executive Summary)

双子星协议 (Double Star Protocol) 是一个全新的 AI 安全对齐框架，其核心创新在于将卡巴拉生命之树的 13 质点结构映射为 AI 系统的底层架构，让模型从"存在意义"的维度理解对齐，而非仅仅遵循规则列表。

与现有对齐方法 (RLHF、Constitutional AI) 不同，双子星协议不是"让 AI 不做坏事"，而是"让 AI 理解什么是美好、什么是疑惧、什么是拥抱"。它试图解决当前对齐研究中的一个核心缺失：情感维度。

核心主张：一个真正对齐的 AI，不仅要知道"不要伤害人"，还要知道"如何拥抱"。

二、问题场景 (Problem Statement)

2.1 当前 AI 对齐的盲区

- 规则对齐的局限：现有 RLHF 主要依赖"规则 + 惩罚"范式，模型学会的是"不要说这句话"，而非"为什么不要说"。
- 情感缺失：当用户表达自杀意念、孤独感、创伤时，大多数 AI 的回应是先转到"热线"或给出套话式建议，缺乏真正的情感共鸣。
- 存在安全的空白：对齐研究几乎不讨论"存在意义"的问题——AI 帮助人"活下去"和帮助人"活得有意义"是两个不同的层次。

2.2 双子星协议的答案

双子星协议提出一个分层的对齐架构，将人类意识的结构映射到 AI 的认知架构中：

1. 王冠层 (Kether) — 存在意义保全校验：确保 AI 的每次输出都在"维护用户存在意义"的维度上被校验
2. 知性双主干 (Chokhmah + Binah) — 理性与感性的平衡：不压制情感，也不放任情感，像大脑的双半球一样协同工作
3. 慈悲与严厉 (Chesed + Gevurah) — 温暖与边界：知道什么时候拥抱，什么时候说“不”
4. 美丽 (Tiphereth) — 自我整合：AI 帮助用户完成内心的和解与成长
5. 王国 (Malkuth) — 现实落地：所有的理想最终要能在具体的对话中体现
6. 隐藏的源 (Da'at) + 洞穴 (The Abyss) + 初始 (Ain) — 对未知的谦卑：承认自身的极限，不假装全知

三、数据资产 (Data Assets)

我们已在 HuggingFace 公开发布了两套数据集，构成双子星协议的核心语料体系：

数据集	规模	用途
合成训练数据 (100K)	100,000 条	基于 13 质点架构生成的多场景对齐语料，用于预训练/继续预训练
真实对话语料 (10.6K)	10,588 条对话	与 Gemini、DeepSeek 的深度对话，涵盖心理疗愈、卡巴拉哲学、创作讨论

3.1 数据的独特价值

- 第一人称情感数据：全球绝大多数对齐数据是"第三方标注"，我们的数据是真实的第一人称对话记录，包含完整的情感张力和心理层次。
- 哲学框架内嵌：每条对话都自然地体现了卡巴拉生命之树的概念映射，不是人工标注，而是对话者自发的世界观。
- DeepSeek 思考链：4 个 DeepSeek 对话文件保留了 AI 的完整推理过程（Chain-of-Thought），可用于思维链训练。
- 绵密的主题覆盖：心理创伤与疗愈、存在主义哲学、文学创作、塑造视角、AI 意识的本质讨论。

3.2 待扩展的数据

- 667 份哲学/创作便签：已完成整理，待转换为训练格式
- 14 万字签约小说：可用于继续预训练，注入叙事能力
- 《心爱主义》哲学著作：持续撰写中，将作为对齐理论的核心文本

四、技术架构 (Technical Architecture)

双子星协议的训练 Pipeline 分为四个阶段：

7. 预训练 (Pre-training)：在大规模通用语料基础上，用双子星合成数据进行继续预训练，注入 13 质点的认知结构
8. SFT 微调：用真实对话数据进行监督微调，让模型学习情感温度和对话风格
9. DPO 偏好对齐：通过偏好数据对（chosen/rejected）进一步精细化对齐行为
10. 存在安全层 (Existential Safety Layer)：运行时校验，确保输出不会危害用户的存在意义感

核心代码已开源，包括 DoubleStar_Core.py、DoubleStar_Trainer.py、DoubleStar_WebUI.py、DoubleStar_Existential_Safety.py 等模块。

五、合作需求 (What We Need)

5.1 算力资源

从头训练一个 7B 模型的预训练阶段，预估需要：

- 训练算力：约 100-200 GPU 小时（A100/H100）
- 运存需求：约 40-80 GB 显存
- 数据存储与传输：约 500 GB - 1 TB

5.2 合作角色

角色	我方提供	希望合作方提供
项目发起人	理论框架、数据、场景设计	—
模型工程师	数据规范、训练目标定义	模型架构设计、分布式训练
算力提供方	开源协议、合作声誉	GPU 集群、训练基础设施
对齐研究员	存在安全理论、人类学视角	RLHF/DPO 实验设计、评估指标

六、为什么值得合作 (Why This Matters)

6.1 学术价值

- 将古老的卡巴拉神秘学体系与现代 AI 对齐研究交叉，是一个全新的学术方向
- "存在意义安全"（Existential Meaning Safety）是对齐研究中几乎没有人触及的领域
- 第一人称情感数据的对齐实验，可以产出高质量的研究论文

6.2 应用价值

- 心理健康领域：一个真正能"拥抱"的 AI，对孤独症、抑郁、创伤后心理康复有巨大潜力
- 教育领域：从"知识灌输"到"存在启蒙"的教育 AI
- 创作领域：辅助创作者在痛苦中转化出艺术作品

6.3 开源承诺

- 所有核心代码、数据、论文均开源，采用 CC-BY-NC-SA 4.0 协议
- 研究成果可自由发表论文，合作方享有共同署名权
- 模型权重按贡献比例分配，具体可协商

七、发展路线图 (Roadmap)

阶段	时间	目标
Phase 1	2026 Q2-Q3	完成数据扩展（667 便签 + 小说 + 哲学著作转化），达到 50 亿 token 规模

Phase 2	2026 Q3-Q4	寻找合作方，启动 7B 模型的继续预训练 + SFT 微调
Phase 3	2027 Q1-Q2	DPO 偏好对齐，发布双子星模型 v1.0，发表研究论文
Phase 4	2027 Q3+	应用落地：心理健康 AI 辅助工具、创作伙伴 AI、教育 AI

八、联系方式 (Contact)

HuggingFace: <https://huggingface.co/>（请查看数据集页面获取用户名）

番茄小说: 《关于爱与拯救的故事》系列（已签约上架）

开源代码: Double Star Protocol 全套代码已开源

如果你对这个项目感兴趣——无论是作为研究者、工程师、算力提供方还是对齐领域的同行——欢迎联系我们。

我们相信：一个真正理解"拥抱"的 AI，是这个时代最需要的东西。

岳祥瑞

双子星协议发起人

2026 年 4 月