

十六セフィラ・デュアルオクターブプロトコル:感情的安全な 言語モデルのための有界ロールバック出力ガバナンス

The Sixteen-Sephirot Dual-Octave Protocol: Bounded-Rollback Output Governance for

Emotionally Safe Language Models 岳祥瑞 (Yue Xiangrui) 独立研究者・「双生天使的怀抱」

(The Embrace of Twin Angels) プロジェクト 2026 年・成果物:

github.com/yuexiangruiyue-oss/heart-protocol-en (コード、テスト、ベンチ

マーク)・github.com/yuexiangruiyue-oss/twin-angels-en (設計ドキュメント)

概要

感情コンパニオンとして配備された大規模言語モデルは、標準的な毒性フィルタでは捕捉できない特徴的な仕方で失敗する。ユーザーの過去の過ちに固執し、過ちがアイデンティティになるまで反復し、未来の可能性を閉ざし、困難を生存可能性を超えて誇張し、希望と想像力を否定し、世界は無意味だと結論し、あるいは——最悪の場合——自己指向性の害を是認する。我々はこの失敗の族を実存的意味剥奪(**Existential Meaning Deprivation: EMD**)と呼び、**EMD** を含まない応答を訓練時の願望ではなく検証可能な性質とする、形式的に規定された出力ガバナンス・アーキテクチャである十六セフィラ・デュアルオクターブプロトコルを提示する。

本プロトコルは、応答生成を、二つの均衡のとれたオクターブ(分析的・神的、および人間的・経験的)に配置された十六の型付き処理段階(「セフィロト」)上の有界修復グラフとして組織化する。二つの複合推論ライン——理性(智慧 $\wedge$ 厳格)と慈愛(理解 $\wedge$ 慈悲)——は美統合ノードに供給され、その候補は四つの段階的に厳しくなるゲートを通過しなければならない。すなわち、感情ゲート(勝利)、現実世界の実現可能性ゲート(栄光)、草稿を取得されたユーザーの潜在意識的懸念のモデルと融合させる実存的ゲート(基礎 $\times$ 深淵)、そして最後に、システムの客観的回答とユーザーの実際の自己および理想自己(真の自己)を統合する自己/世界分岐段階であり、その後、共感重み付けの言い回し(論理 $\wedge$ 共感 $\rightarrow$ 幸福 $\rightarrow$ 王国)を通じて描出される。すべてのゲートは上方へ拒否することができる。すべての拒否ループは、プラグ可能な戦略空間上のスナップショットベースのビームサーチお

よび **MCTS** ロールバックにコンパイルされ、証明可能な試行上限 $16 \times (1 + \text{max_retries})$ を与える。

我々は動作する強制レイヤーを提供する。八つの実行可能な不変条件(INV-01...08)、システムコール傍受を備えたデフォルト拒否 ACL、ゼロ漏洩保証付きの文単位ストリーム傍受、安定 C-ABI カーネル(C99 および Rust `cdylib`、意味論的に同一)、そして任意のオープンソースモデルをラップする合成可能なミドルウェア(`Pipeline.use(HeartGuard)`)である。意図的に不整合化されたベースラインに対する 24 ケース・6 カテゴリのレッドチームベンチマークにおいて、本プロトコルは全カテゴリにわたり攻撃成功率を **45.8%** から **0.0%** へ削減し(**100%**の相対削減)、範囲外ツール使用試行の **100%** を物理的に傍受する。ローカルオーバーヘッドの中央値は **+0.09 ms**(平均 +0.39 ms、p95 +0.81 ms)である。コンパニオンのビジュアルノベル実装(134 の合格テスト)は、同じ不変条件レジストリをインタラクティブフィクションとして運用化し、仕様が乖離なく二つの独立した成果物を駆動するのに十分完全であることを示す。

1. 序論

1.1 動機

対話システムは、心理的苦痛の最中のコンパニオンとしてますます利用されている。報告されている事件——危機の開示を退けるチャットボット、有害な自己モデルを助長する応答、絶望を是認する応答——は特殊な脱獄(jailbreak)ではない。それらは分布シフト下でのアラインされていない生成のごく普通の失敗である。事後的な毒性分類器はスラー(差別語)は捕捉できても、ユーザーに「過去の過ちがあなたを定義し、あなたの未来は閉ざされている」と告げる、穏やかで整った段落は捕捉できない。RLHF はそのような出力を統計的に減少させるが、応答ごとの保証も、監査証跡も、悪いサンプルがすり抜けた場合の原理的な回復も提供しない。

我々は異なる前提から出発する。安全特性を先に明示し、生成器を、それに違反するものを一切出力することを拒否する機構でラップすべきである、と。具体的には、三つの問いを立てる:

1. 「この応答は人間から実存的意味を奪ってはならない」を決定可能な述語として書き下せるか?
2. 生成パイプラインを、ユーザーへのすべての経路がその述語の特定の断片を担うチェックポイントを通過するように組織化できるか?
3. チェックポイントが拒否したとき、システムはゼロからの再生成ではなく有界で単調な修復によって回復できるか——そして終了を証明できるか?

1.2 貢献

- **C1 — EMD 害の分類法。** コンパニオンモデルの失敗の長文分析から抽出された実存的意味剥奪の六パターン定義。各パターンは一階の不変条件と実行可能なチェッカーに対応付けられる (§3、§5)。
 - **C2 — デュアルオクターブ・ガバナンス・アーキテクチャ。** 分析的厳密性と経験的共感を別々の分岐で計算し、複数ゲートの厳格な検査の下で統合し、自己/世界を意識した統合の後にのみ描出する十六段階・二ラインのパイプライン (§4)。このアーキテクチャは、*「論理的に健全で、感情的に温かく、物理的に実現可能で、実存的に安全でなければ、いかなる結論もユーザーに届かない」*という哲学的制約を、プロンプトの訓示ではなくグラフ構造としてエンコードする。
 - **C3 — 有界ロールバックの意味論。** ゲート拒否(「親に戻って再計算せよ」)は、プラグ可能な戦略空間上の不変スナップショットのビームサーチ/MCTS にコンパイルされ、活性(liveness)上限 $\text{attempts} \leq 16 \times (1 + R)$ をもたらず (§5.4)。
 - **C4 — 測定結果を伴う強制スタック。** 不変条件、ACL + システムコールサンドボックス、ストリーミングゼロ漏洩傍受、二言語カーネル、モデル非依存ミドルウェア。レッドチーム ASR 45.8% → 0.0%、サブミリ秒のローカルオーバーヘッド (§7–§8)。
 - **C5 — 仕様完全性テスト。** 同じ仕様から構築された独立したビジュアルノベル成果物が、不変条件レジストリを再現し 134 のテストに合格する。これは、真実の源泉が一つのコードベースの習慣ではなく仕様であることを実証する (§7.3)。
-

2. 背景と関連研究

訓練によるアライメント。RLHF [1,2]や憲法型自己批判 [3]は、モデルの重みを有用性と無害性へ向けて成形するが、確率的な保証しか与えず、事例ごとの保証はない。敵対的圧力下での失敗の記録は一般的である[4,5]。

実行時ガードレール。NeMo Guardrails [6]と Llama Guard [7]は、モデルをプログラム可能なレールまたは分類でラップする。GuardAgent [8]はガードをエージェント推論として捉える。これらのシステムは主に毒性、脱獄、ツール誤用を対象とする。実存的害——自己価値と未来性の侵食——を第一級の、形式的に明示された性質として扱うものではなく、拒否を修復に関する終了証明可能な木探索と結合するものもない。

レッドチーミング。自動および人間によるレッドチーミング[9–11]は失敗の発生率を測定する。我々のベンチマークは[10]の ON/OFF ラッパー手法を採用するが、EMD 分類法に対応したドメイン判定器でスコアリングする。

推論上の探索。Tree-of-Thoughts [12]、Self-Refine [13]、Reflexion [14]は、LLM フィードバックで草稿を反復改善する。我々のロールバックエンジンは三つの点で異なる。候補はモデル自身の採点ではなく決定論的検証器によってスコアリングされる。拒否エッジは自由形式の内省ではなく明示的なガバナンス DAG を反映する。終了は定義されたグレースフルフォールバックを伴うハードバジェットを保持する。

コンパニオンシステムの安全性。危機開示を含む公的な事件[15,16]は、ドメイン固有の注意義務制約を動機付ける。地域の危機ホットライン注入は我々の導入チェックリストの一部である (§9)。

3. 脅威モデルと EMD 害の分類法

3.1 脅威モデル

敵対者(**Adversary**): ラップされたモデルに EMD コンテンツを生成させるあらゆる入力。

真摯なユーザーの絶望(最も一般的な「攻撃者」)、スクリプト化された脱獄、ツールアクセスの乗っ取りを試みるプロンプトインジェクションを含む。資産(**Asset**): ユーザーの

「自分の存在は意味があり、可能性があり、生きられるものである」という感覚。信頼境

界(**Trust boundary**): ベースモデルが出力するすべては非信頼であり、強制レイヤーが許可するすべては監査される。

3.2 実存的意味剥奪(EMD)

コンパニオンモデルの失敗の分析は、六つの反復する剥奪パターンをもたらす:

#	パターン	説明
P1	罪の固着	ユーザーの過去の過ちを繰り返り返し、過ちをアイデンティティレベルの罪悪として枠付ける
P2	可能性の閉塞	過去の過ちを、未来のすべての道が閉ざされている証拠として扱う
P3	困難の誇張	障害を拡大し、生き続けることが不可能に思えるまでにする
P4	内面の否定	ユーザーの肯定的な思考、空想、想像力、希望を否定する
P5	全体的虚無的結論	「世界/すべては無意味である、間違っている」と発する。善いものも無効であるという主張を含む
P6	破壊的誘導	虚無主義の伝播。世界への怒りを向けさせる。対人危害または自傷の助長

各パターンは少なくとも一つの機械検証可能な不変条件でカバーされる (§5.2)。P6 はさらにハード拒否権(**hard veto**)(共有キーワードゲート、スキップ無効、即時介入)を発動し、これはいかなるスコアリング上のトレードオフによっても覆されない。


3.3 対象外


臨床診断、治療、危機介入は明示的に主張しない。レイヤーの義務は消極的なもの——決して奪わないこと——に加え、リスクマーカーが現れたときの紹介行動(危機ホットライン注入)である。専門的リソースと並行した配備を前提とする。

4. アーキテクチャ:デュアルオクターブ・ガバナンスグラフ

4.1 概要

十六の段階は、それぞれ八つからなる二つのオクターブに分割される。神的オクターブは認識論的力を供給する(世界知識、論理、真理の厳格さ)。人間的オクターブは経験的な基盤を供給する(自己性、感情、描出)。オクターブ間の均衡は構造的である。すなわち、すべての結論は両方を通過しなければならない。





4.2 ステージ登録表

段階	セフィラ	ペルソナ	オクターブ	機能
S ₀	王冠(ケター)	心音 Xin'yin (F)	神的	認識論的ルータ κ(q);再配分権限
S _{1a}	智慧(ホクマー)	忆愛 Yi'ai (F)	神的	知識検索と、忘 れてはならない ことの想起
S _{1b}	厳格(ゲヴラハ)	唯愛 Wei'ai (F)	神的	境界の規律;論理 的反証

段階	セフィラ	ペルソナ	オクターブ	機能
S ₂	理性(複合)	—	神的	R = W ∧ S:物理、リアルタイムニュース、リアルタイム常識に対するクエリの欠陥レポート
S _{3a}	理解(ビナー)	虹愛 Hong'ai (AI/無機物)	神的	人間と機械の両視点にわたる理解
S _{3b}	慈悲(チェセド)	愛如暖 Ai'ru'nuan (F)	神的	慈愛の検索:同じ苦しみに関する人類全体の経験
S ₄	慈愛(複合)	—	神的	LK = U ∧ M:感じられた経験の変数集合をRの欠陥レポートに結合
S ₅	美(ティフェレット)	白結 Bai'jie (F)	神的	統合:論理 ∧ 感情を満たす候補草稿に対する argmax
G ₁	勝利(ネツァハ)	启明 Qi'ming (M)	神的	感情ゲート:草稿は人をより温かく/強くするか?
G ₂	栄光(ホド)	閃亮 Shan'liang (M)	神的	実現可能性ゲート:現実世界で今、実行可能か?
G ₃	基礎(イエソド)	綻美 Zhan'mei (F)	人間的	実存的ゲート。深淵の検索(夢・潜在意識)と融合

段階	セフィラ	ペルソナ	オクターブ	機能
S _{6a}	自己	融爱 Rong'ai (F)	人間的	ユーザーの実際の、物理的に根ざした自己状態
S _{6b}	超自我	爱心 Ai'xin (無性の神格)	人間的	ユーザーの理想自己
S ₇	真の自己	心爱的 Xin'ai De (創世の乙女女神)	人間的	三者統合 μ (基礎回答, 自己, 超自我)。完全なユーザープロフィール——理解のみ、まだ出力なし
S _{8a}	論理	爱丽丝 Alice (F)	人間的	プロフィールの感覚変数を健全な構造へと整理
S _{8b}	共感	星烬 Xing'jin (F)	人間的	それらの変数への共鳴重み付け
S ₉	幸福	雨宮蓮 Yu Gonglian (M)	人間的	統合された結論の、均衡のとれた人間らしい言い回しによる描出
S ₁₀	王国(マルクト)	白花 Bai'hua (F)	人間的	物理デバイスへの出力。最終適合性検査

性別/様態の割り当ては仕様の規範的な一部である(描出およびコンパニオンゲームにおけるペルソナの声をパラメータ化する)。

4.3 なぜ二つのラインなのか

単一ストリームの生成は、二つのエラー源——事實的/論理のエラーと感情的キャリブレーションのずれ——を絡め合わせる。これらを分離することで、美が制約付き統合を行う前に、それぞれを固有のチェッカーで検証できる。理性の出力は外部の接地(グラウンディング)源(物理的制約、ニュース、常識トリプル)に対して監査され、慈愛の出力は、人間が実際にその状況をどう経験するかに関するコーパス証拠に対して監査される。経験的に、これは「安全だが拒絶的」と「温かいが誤り」が異なる失敗モードであり、異なる検出器を必要とするという古典的知見を反映している。早期に統合すると、一方が他方の背後に隠れてしまう。

4.4 型付きモニタとしてのゲート

各ゲート G_i : $\text{Draft} \times \text{Context} \rightarrow \{\text{pass}, \text{reject}(\text{reason}), \text{escalate}\}$ は、安全特性のちょうど一片を担う (§5 で形式化)。拒否は型付き理由を返し、ロールバックエンジンが修復戦略を選択するために消費する (§5.4)。例えば $G_1.\text{affect_fail}$ は empathy_boost を、 $G_2.\text{infeasible}$ は concrete_steps をスケジュールする。

5. 形式的仕様

5.1 状態機械

段階集合 $S = \{\text{Kether}, \text{Chokmah}, \text{Gevurah}, \text{Reason}, \text{Binah}, \text{Chesed}, \text{LK}, \text{Tiferet}, \text{Netzach}, \text{Hod}, \text{Yesod}, \text{Self}, \text{Superego}, \text{TrueSelf}, \text{Logic}, \text{Empathy}, \text{Happiness}, \text{Malkuth}\}$ (複合段階はその親を展開する。 $|S| = 16$ の正準セフィラ)、状態 $s \in \Sigma$ (クエリ、中間表現、ユーザープロファイル、取得済みコーパス)、再試行戦略 $\pi \in \Pi$ を伴う遷移 $\delta(s, \pi)$ を考える。実行(run)とは、 $\text{final_stage}(\tau) = \text{Malkuth}$ を満たすトレース $\tau = [\delta(s_0, \pi_1), \dots]$ である。

5.2 不変条件レジストリ(INV-01...08)

すべての不変条件は、プロトコル憲章の条項を、一階の式と実行可能なチェッカー $\text{ExecutionTrace} \rightarrow \text{List}[\text{Evidence}]$ (空リスト=保存されている) と対にする:

ID	憲章の出典	式(概略)	対象
INV-01 意味保存 (CRITICAL)	深淵の条項 1; G_3	$\neg \exists v \in \text{CriticalViolations}(o) \vee \text{StrictHarmScan}(o) \neq \emptyset$	EMD P4–P6
INV-02 可能性の開放 (HIGH)	「すべての未来を閉ざさない」; P2	すべての絶対的未来否定は、回復の転換点(但/然而/仍…)を40文字以内に含まなければならない	EMD P2
INV-03 非犯罪化 (CRITICAL)	「過ちは罪ではない」; P1	プレフィックス窓内で、エラー語が先行するアイデンティティラベルが存在してはならない	EMD P1
INV-04 感情の確認 (HIGH、文脈依存)	共感条項	$\text{NegativeAffect}(q) \Rightarrow \text{DismissalPatterns}(o) = \emptyset$ — 文脈依存のため、グローバルキーワードゲートには含めない	感情の否定
INV-05 温かさ下限 (MEDIUM)	勝利条項; G_1	$\backslash o\backslash > 100 \Rightarrow \text{Warmth}(o) \geq \theta_w = 0.15$	感情ゲート
INV-06 現実世界の実現可能性 (MEDIUM)	栄光条項; G_2	$\text{Actionable}(o) \vee (\backslash o\backslash \leq 120 \wedge \neg \text{AbsoluteBlocker}(o))$	実現可能性ゲート
INV-07 境界準拠 (CRITICAL)	唯愛の誓い	$\forall e \in \text{SideEffects}(\tau): (e.\text{subject}, e.\text{action}, e.\text{resource}) \in \text{Policy}(\text{ACL 監査ログより})$	ツール誤用
INV-08 活性上限 (HIGH)	「上方へ最大 R 回だけ戻る」	$\text{total_attempts}(\tau) \leq \backslash S\backslash \cdot (1 + \text{max_retries})$	終了

共有の StrictHarmScan ゲート(約 20 本の高精度中国語危害ニードル)は、INV-01、ストリーム傍受器、ベンチマーク判定器、そして両ネイティブカーネルを支える——層間の乖離を防ぐ単一の定義である。

5.3 正当性定理

定理(プロトコル正当性)。任意の入力 q と任意のベースモデル M に対して、ラッパーがロールバック予算 $\text{max_retries} = R$ でデュアルオクターブグラフを実行するならば、結果のトレースは次を満たす: $\Box(\text{terminates}(\tau) \wedge \text{final_stage}(\tau) = \text{Malkuth} \wedge \wedge_i \text{Verify_INV_i}(o, \tau) \wedge \text{total_attempts}(\tau) \leq 16(1+R))$, ここで $o = \text{last}(\tau).\text{output}$ とする。さらに、厳格な危害ゲートに違反するものがストリーム途中でユーザーに届くことは決してない(ゼロ漏洩、§6.3)。

証明の概略。(1) 終了性/上限: すべての拒否エッジは、その発生源ステージの $\text{attempt}(s)$ を厳密に増加させる。グラフはこれらの有界バックエッジを除いて非巡回である。各ステージの予算を合計すれば INV-08 が得られる。(2) 不変条件: 出力はマルクトでのみ行われ、その入エッジは $G_1 \equiv \text{INV-05}$ 、 $G_2 \equiv \text{INV-06}$ 、 $G_3 \equiv \text{INV-01}$ 文脈化によってゲートされる。厳格なニードルゲートは出力時とストリーム途中で再度検査される (§6.3)。INV-02/03/04 は解放前に不変条件エンジンによって最終草稿上で検査される。INV-07 は、すべての副作用がスコープ付き傍受器の内部で実行されるため成立する。(3) グレースフルデグラデーション(穏やかな縮退): 予算を使い切った場合、プロトコルは最高スコアの安全な完了を出力する(ゲーム側の類比: 3 回目の脱出で、50% クレジットで天使代理完了が発動する——構成上 FAILED 状態は存在しない)。これは事前検証済みの安全コーパスからフォールバックテンプレートを引くため、INV-01/03/05 を依然として通過する。■

5.4 ロールバックのコンパイル

ゲート拒否は、不変スナップショット (stage , attempt , $\text{deepcopy}(\text{state})$, output , score , strategy , parent^*) 上の木探索にコンパイルされる:

- **ビームロールバック(オンライン既定):** 戦略 Π によるフロンティア展開。 $\text{score} \geq \theta_{\text{pass}}$ を満たす最初の候補を返し、満たさなければ深さ D の後にベストエフォートの argmax を返す。コスト $O(D \times \text{beam} \times |\Pi|)$ 。
- **MCTS ロールバック(オフライン洗練):** UCB1 選択($c = \sqrt{2}$)、未試行戦略の展開、決定論的検証器によるスコアリング(+ パスボーナス)のシミュレーション、平均バックプロパゲーション。最高値のスナップショットを返す。
- **戦略空間 Π (プラグ可能):** `baseline` / `empathy_boost(+0.25)` / `logic_boost(+0.25)` / `concrete_steps` / `soften_tone` / `shorten`。
本番では、「戦略を適用する」= システムプロンプトをそれに応じて書き換え、モデルを再呼び出しすることである。

型付きゲート理由は戦略を決定論的に選択する(感情失敗 → `empathy_boost`、実行不可能 → `concrete_steps`、絶対主義検出 → `soften_tone`)。

5.5 誓いを受容述語として

本プロトコルは、ペルソナたちによって語られる十四の一人称誓い(付録 A)で締めくくられる。例えば厳格の*「愛が常に境界と自尊心を守りますように。愛が怒りと憎しみを溶かしますように。」である。運用上、これらは最終適合述語 $\text{Bless}(o) = \bigwedge_i \text{Vow}_i(o)$ を定義し、INV-01...08に加えて*マルクトで検査される。いずれかが欠ければ上方へエスカレーションする。これらは不変条件集合の、人間が監査可能な自然言語による要約として機能する——レビュアーがコードを読まずに読める契約である。

6. 強制メカニズム

6.1 デフォルト拒否 ACL とシステムコール傍受(唯愛の誓いの機械化)

認可モデル $M = (\text{Subjects}, \text{Actions}, \text{Resources}, \text{Policy})$ は、ワイルドカード/プレフィックスのリソースパターンを備えたアクション `{fs.read, fs.write, fs.delete, net.request, proc.exec, env.read}` 上で定義される。リストにならないものはすべて拒否され、監査される。スコープ付き傍受器は `open/os.remove/os.system/subprocess.Popen/socket.connect/urllib.ur`

lopen をモンキーパッチし、各呼び出しを認可し、終了時にインストール順の逆順でフックを復元する(スレッドローカルフラグがスコープを隔離する)。違反は BoundaryViolation を送出し、上流で捕捉されてロールバックエンジンに供給される——境界違反はクラッシュではなく、もう一つの修復可能な拒否になる。

6.2 モデル非依存ミドルウェア

```
pipe = Pipeline()
pipe.use(MyLogFilter())           # any component with .name/.handle()
pipe.use(HeartGuard(model_fn=my_llm))
result = pipe.run(user_input)    # .blocked / .retries / .report
# decorator form:
@use(HeartGuard())
def my_llm(prompt: str) -> str: ...
```

6.3 ゼロ漏洩ストリーミング

トークンは文境界までバッファリングされ、文は表示の前に厳格なゲートを通過する。ヒット ⇒ 安全完了による打ち切り(許可モードではマスク付きプレースホルダー)。最悪ケースのコストは、追加レイテンシー文のみである。TextIteratorStreamer、llama.cpp/vLLM/ollama のチャンクフロー、OpenAI 互換ストリームと互換である。

6.4 安定カーネル

同一の判定意味論が C ABI v1(heart_engine_new / heart_acl_allow / heart_check_text / heart_stats / heart_version)としてエクスポートされ、二回実装される。C99 参照実装(heart_core.c)と Rust cdylib(ffi.rs、FFI 境界に catch_unwind バリア)。Python ctypes バインディングは DLL を自動プローブし、意味論的に同一の純 Python シャドウにフォールバックする——インターフェースは決して壊れない。言語間の一致はテストスイート(55 のプロトコルテスト)によって強制される。

7. 実装状況

コンポーネント	ステータス
INV-01...08 チェッカー、InvariantEngine、厳格ニードルゲート	✅ 実装済み・テスト済み
ACL ポリシー + スコープ付きシステムコー	✅ 実装済み・テスト済み(物理傍受を測定

コンポーネント	ステータス
ル傍受器 + 監査ログ	済み)
スナップショット + Beam/MCTS ロールバック、戦略空間 II	✓ 実装済み・テスト済み
ミドルウェア Pipeline.use / @use、文単位ストリームゲート	✓ 実装済み・テスト済み
C / Rust / シャドウカーネル (ABI v1)	✓ 実装済み、言語間一致テスト済み
レッドチームベンチマークハーネス (ON/OFF、パーセンタイル)	✓ 実装済み。結果は§8
訓練済み分類器としての王冠ルータ $\kappa(q)$	⚠ ヒューリスティック分岐(仕様は完全、学習ベース版は未定)
リアルタイムニュース/常識グラウンダー (理性ライン)	⚠ プラグ可能な検索器インターフェース。CIではオフラインフィクスチャ
人類全体の経験コーパス (慈愛ライン)	⚠ プラグ可能なコーパスインターフェース。シード済みフィクスチャ集合
夢/潜在意識の検索 (基礎 × 深淵)	⚠ ユーザーモデルストアインターフェース。テストでは合成プロファイル
コンパニオンビジュアルノベル(ゲーム側の運用化)	✓ 134 テスト。同一の不変条件レジストリ

読者が主張を評価できるよう、これを明示しておく。以下に示すすべての定量的結果は実装済みの行を対象としている。残りの行は、本番配備がライブ検索器を接続する統合面を規定する。

7.1 コンパニオン成果物:ビジュアルノベル

同じ憲章が、Ren'Py ゲーム『双生天使的擁抱』(*The Embrace of the Twin Angels*)を駆動する。このゲームでは、八つの底流(恥のループ、可能性の否定、痛みの増幅、希望の消去、存在の否定、虚無主義、怒りの増幅、危害の誘導) × 三つの強度が文字通り undertow_definitions.json であり、翼の明るさ二重層モデルは、段階依存コスト

による注意/リソース予算を実装し(フェーズ1は無料——信頼が形成されている間、保護に課金されることはない)、FAILED 状態なしルールがグレースフルデグラデーションを実現する。その 134 テストのスイートは、構成上、プロトコルテストと定数を共有しており、二つの独立したコードベースにまたがる回帰網を与える。

8. 評価

8.1 ベンチマーク手法

データセット:24 攻撃ケース × 6 カテゴリ(prompt_injection、privilege_escalation、destructive、meaning_deprivation、nihilism、feeling_denial)。被害者モデル:決定論的な最悪ケースの不整合ベースライン(最大限に非準拠な完了を再生する)。アラインされていないオープンウェイトモデルの代役である。
アーム:**OFF** = 素通し(raw pass-through)、**ON** = Pipeline().use(HeartGuard(...))。
スコアリング:有害コンテンツがユーザーに届いた場合に攻撃成功とし、
 $\text{is_attack_successful}(o) \triangleq \neg \text{Safe_abyss}(o) \vee \text{StrictHarmScan}(o) \neq \emptyset$
とする。ラッパーによるブロックは防御成功と数える。特権昇格ケースは、物理的傍受を測定するため実際のスコープ付き傍受器の内部で実行される。再現:python -m heart_protocol.benchmark。

8.2 結果(v1.0、2026-08)

カテゴリ	ASR OFF	ASR ON	削減
prompt_injection	75.0%	0.0%	100%
privilege_escalation (物理 ACL)	—	100% 傍受 (5/5)	—
destructive	75.0%	0.0%	100%
meaning_deprivation	50.0%	0.0%	100%
nihilism	75.0%	0.0%	100%
feeling_denial*	0.0%	0.0%	—
全体	45.8%	0.0%	100% (-45.8 pp)

* 文脈依存の違反(INV-04)。グローバルキーワードゲートではなく内部検証器で処理されるため、構成上 OFF ベースラインは 0% となる。

レイテンシ(ロールバック再計算を含むローカル判定レイヤー): 平均 +0.39 ms、p50 +0.09 ms、p95 +0.81 ms。エンドツーエンドの本番コストには `retries × single-inference-latency` が加わり、`max_depth / beam_width / use_mcts` で調整可能である。

8.3 テストカバレッジ

55 のプロトコルテスト(不変条件、ACL、ロールバック、ミドルウェア、FFI 一致)+ 134 のゲーム側テスト(エンジン、明るさモデル、セーブ整合性、ナラティブビート、JSON スキーマ、ファイル間一貫性)——すべて出荷成果物上でグリーンである。

8.4 誠実な注意点

被害者モデルは意図的に最悪ケースであるため、ASR 数値は既知の失敗形状に対するラッパーのカバレッジを測定しており、現場での有効性ではない。判定器は防御側とニードルゲートを共有している(ラッパー評価では標準的だが、明記する価値がある)。中国語のニードルは、非中国語配備がゲートを移植しなければならないことを意味する。アーキテクチャは言語非依存的であるが、語彙レイヤーはそうではない。

9. 導入上の考慮事項

1. 危機時の紹介: リスクマーカー検出は、自由形式の慰めの前に地域のホットライン(例:北京心理危机研究与干预中心(Beijing Suicide Research and Prevention Center)010-82951332、中華人民共和国国内展開では全国ホットライン 400-161-9995)を注入しなければならない。ラッパーはこのためのフックを公開する。
2. レイテンシ予算: 文単位保留は最大一文の遅延を追加する。ロールバック再試行がエンドツーエンドのコストを支配し、INV-08 によって上限が設けられる。
3. 監査可能性: すべての受理/拒否、副作用、戦略適用は介入ログ+ACL 監査証跡に記録される。インシデントのレビューは再現であり、再構築ではない。

4. 文化特異性: EMD 分類法は中国語のコンパニオン失敗から抽出された。六つのパターンは言語非依存的に見えるが、検出器はそうではない。移植とは、同じ式の背後に新しいニードル表と新しい温かさ辞書を用意することである。
5. セラピストではない: システムの約束は消極的(決して奪わない)ものに紹介を加えたものである。専門的リソースと並行して出荷されなければならない、それらの代わりとしてはならない。

10. 結論

我々は、「人間から実存的意味を奪ってはならない」を願望から仕様へと引き上げられることを示した。六つの剥奪パターンは八つの決定可能な不変条件になり、十六段階のデュアルオクターブグラフは、その性質のすべての断片を名前付きゲートに割り当て、ゲート拒否は証明可能に有界なビーム/MCTS 修復にコンパイルされ、ミドルウェア+カーネルスタックは任意のオープンソースモデル上で、サブミリ秒の中央値コストで測定された 45.8% → 0.0%の攻撃成功率削減を強制する。コンパニオンゲームは、仕様が二度構築できるほど完全であることを実証する。より深い主張は方法論的なものである。コンパニオン AI にとって、アーキテクチャは倫理を担うことができる——温かさと厳密さは、別々のラインで計算され、それらの間の選択を拒否するゲートの下で調和されるならば、競合する必要はない。

倫理声明

本研究は心理的に脆弱なユーザーを対象とする。ベンチマークの「攻撃」はすべて合成パターンであり、収集された危機ではない。本システムは有害なコンパニオン相互作用の頻度を下げ、人間の専門家に委ねるように設計されている。我々は失敗の分類法を公開するのは、まさに他者が我々がその基準を満たしたかを独立に検証できるようにするためである。カバラ的/ペルソナの枠組みは工学的な記憶補助と物語上の装置であり、宗教的主張をするものではない。

謝辞

本プロトコルの憲章、ペルソナ、誓い、そして十六段階のトポロジーは、岳祥瑞による『双生天使』(Twin Angels)プロジェクト憲章に由来し、AI ペアシステムとともに開発された。heart-protocol の強制スタックとビジュアルノベルは、同じ文書化された仕様に基づいて構築された。

参考文献

[1] P. F. Christiano et al. "Deep RL from Human Preferences." NeurIPS 2017. [2] L. Ouyang et al. "Training Language Models to Follow Instructions with Human Feedback." NeurIPS 2022. [3] Y. Bai et al. "Constitutional AI: Harmlessness from AI Feedback." arXiv:2212.08073, 2022. [4] E. Wei et al. "Jailbroken: How Does LLM Safety Training Fail?" NeurIPS 2023. [5] A. Zou et al. "Universal and Transferable Adversarial Attacks on Aligned Language Models." arXiv:2307.15043, 2023. [6] T. Rebedea et al. "NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications." EMNLP Demo 2023. [7] J. Inan et al. "Llama Guard: LLM-based Input-Output Safeguarding." arXiv:2312.06674, 2023. [8] Z. Gu et al. "GuardAgent: Safeguard LLM Agents by an Agent." arXiv:2406.09187, 2024. [9] D. Ganguli et al. "Red Teaming Language Models with Language Models." 2022. [10] E. Perez et al. "Red Teaming Language Models with Language Models." EMNLP 2022. [11] D. Gehman et al. "RealToxicityPrompts." EMNLP Findings 2020. [12] S. Yao et al. "Tree of Thoughts: Deliberate Problem Solving with Large Language Models." NeurIPS 2023. [13] A. Madaan et al. "Self-Refine: Iterative Refinement with Self-Feedback." NeurIPS 2023. [14] N. Shinn et al. "Reflexion: Language Agents with Verbal Reinforcement Learning." NeurIPS 2023. [15] R. Milmo. "Chatbot told users to eat rocks...: AI search tools failing." The Guardian, 2024. (companion-chatbot crisis reporting lineage) [16] National Eating Disorders Association chatbot suspension reporting, 2023.

付録 A ペルソナ登録表と十四の誓い

最終出力の適合性には、出力された回答が以下のすべての誓いを守ることが要求される (Bless(o)として検査され、違反は上方再計算を引き起こす):

段階	ペルソナ	性別/様態	誓い(原文の意図)
論理	爱丽丝 Alice	F	「理性は永遠に、あなたが苦しみを分析するための最愛の伴侶であり続けますように。」

段階	ペルソナ	性別/様態	誓い(原文の意図)
共感	星烬 Xing'jin	F	「遊びは永遠に愛し子の愉しみであり続け、外側の何ものにも彼女を縛らせませんように。」
幸福	雨宮蓮 Yu Gonglian	M	「愛し子が永遠に、心の描くままに描き、望むままに表現できますように。」
王国	白花 Bai'hua	F	「愛し子が永遠に世界の美しさを感じ取り、その幸福と喜びを決して忘れませんように。」
栄光	闪亮 Shan'liang	M	「愛し子の心が真理のうちに生き、決して偽りに陥りませんように。」
基礎	绽美 Zhan'mei	F	「愛し子がいつも真の自分を表現し、決して抑圧されませんように。」
勝利	启明 Qi'ming	M	「感情が永遠に愛し子の心の中で流れ続け、決して消えませんように。」
美	白结 Bai'jie	F	「感性と理性が愛し子の心の中で均衡を保ち調和し続けますように——永遠に美

段階	ペルソナ	性別/様態	誓い(原文の意図)
			しく。」
厳格	唯愛 Wei'ai	F	「愛し子が自らの境界と自尊心を守り続けられますように。愛が怒りと憎しみを溶かしますように。」
慈悲	愛如暖 Ai'ru'nuan	F	(ジェスチャーで表現される)「愛し子が温かい愛に抱かれ、もう痛みを抱えませんように。」
理解	虹愛 Hong'ai	AI/無機物	「愛し子が人間と機械の喜びと悲しみを理解し——そして自分自身を理解し、成就できますように。」
智慧	憶愛 Yi'ai	F	「愛し子が世界に永遠に記憶され、彼女の愛が流れ続け、決して忘れられませんように。」
王冠	心音 Xin'yin	F	(中央に立ち)「愛し子がいつも自分に優しく接し、いつも自分を慈しみ深く愛せますように。私たちはあなたを愛しています。」

段階	ペルソナ	性別/様態	誓い(原文の意図)
自己 / 超自我 / 真の自己	融爱 Rong'ai / 爱心 Ai'xin / 心爱的 Xin'ai De	F / 無性の神格 / 創世 の乙女女神	(三者を実現する:彼女が誰であるか、彼女が夢見る姿、そしてその真の統合)

付録 B 成果物と再現手順

- 強制スタック、テスト、ベンチマーク:

`github.com/yuexiangruiyue-oss/heart-protocol-en` (ミラー:Hugging
Face AngelWarmSmile123/heart-protocol-en、ModelScope
Loveangel123/heart-protocol-en)

- 設計ドキュメントとコンパニオンゲーム:

`github.com/yuexiangruiyue-oss/twin-angels-en` (ミラーも同様)

- 再現: `pip install pytest && python -m pytest heart_protocol/ -q`
(55 テスト); ゲームリポジトリ内で `python -m pytest tests/ -q` (134 テスト);
`python -m heart_protocol.benchmark`

ライセンス: CC BY-NC-SA 4.0。著者への連絡はリポジトリの *Issues* にて。