

十六质点双八度协议：面向情感安全大语言模型的有界回滚输出治理

The Sixteen-Sephirot Dual-Octave Protocol: Bounded-Rollback Output Governance for Emotionally Safe Language Models

Yue Xiangrui (岳祥瑞) 独立研究者 · 双生天使的怀抱项目 2026 · 制品：

github.com/yuexiangruiyue-oss/heart-protocol-en(代码、测试、基准) ·

github.com/yuexiangruiyue-oss/twin-angels-en(设计文档)

摘要

以情感陪伴角色部署的大语言模型会以标准毒性过滤器无法捕捉的特征性方式失效：它们固着于用户的过往错误，直至错误变成身份；封死未来的种种可能；把困难夸大至超出可承受范围；否定希望与想象；得出世界毫无意义的结论；甚至在最坏情况下认可自我伤害。我们将这一族失效命名为存在意义剥夺(**Existential Meaning Deprivation, EMD**)，并提出十六质点双八度协议(**Sixteen-Sephirot Dual-Octave Protocol**)——一种形式化规定的输出治理架构，它使“无 EMD 响应”成为可检验的性质，而非训练阶段的一厢情愿。

该协议将响应生成组织为一张有界修复图，其节点是排列在两个均衡八度(分析-神界与人界-体验)中的十六个类型化处理阶段(“质点”)。两条复合推理线——理性(智慧 $\wedge$ 严厉)与慈爱(理解 $\wedge$ 慈悲)——汇入一个美丽整合节点，其候选输出必须依次通过四道不断升级的验证门：情感验证门(胜利)、现实可行性验证门(荣耀)、存在验证门(将草稿与检索到的用户潜意识关切模型融合；基础 $\times$ 深渊)，以及最终的自我/世界分岔阶段，它在通过共情加权的措辞渲染之前，综合系统的客观答案与用户的实际自我与理想自我(真我)(逻辑 $\wedge$ 共情 $\rightarrow$ 幸福 $\rightarrow$ 王国)。每一道门都可以向上拒绝；所有拒绝循环都被编译为在可插拔策略空间上的基于快照的束搜索与 **MCTS** 回滚，从而给出可证明的尝试上界 $16 \times (1 + \max_retries)$ 。

我们交付一个可工作的强制层：八条可执行不变量(INV-01...08)、带系统调用拦截的默认拒绝 ACL、带零泄露保证的句级流拦截、稳定的 C-ABI 内核(C99 与 Rust `cdylib`，语义一致)，以及一个可包装任意开源模型的可组合中间件(`Pipeline.use(HeartGuard)`)。在一个 24 例、六类别的红队基准上，对照一个刻意失对齐的基线，该协议将各类别攻击成功率从

45.8% 降至 0.0%(相对降低 100%), 物理拦截 100% 的越界工具调用尝试, 本地开销中位数为 +0.09 ms(均值 +0.39 ms, p95 +0.81 ms)。配套的视觉小说实现(134 项通过测试)将同一不变量注册表落地为交互式小说, 证明该规范完备到足以驱动两个独立制品而无漂移。

1. 引言

1.1 动机

对话系统越来越多地被用作心理困扰期间的陪伴。已报道的事件——聊天机器人无视危机披露、鼓励有害的自我模型、或认可绝望——并非罕见的越狱; 它们是未对齐生成在分布偏移下的普通失效。事后毒性分类器能抓住脏话, 却抓不住那一段温和、语法工整、告诉用户"你的过往错误定义了你是谁、你的未来已经关闭"的文字。RLHF 在统计上降低此类输出, 但不提供逐条响应的保证、不提供审计轨迹, 当一条坏样本漏过时也没有原则性的恢复机制。我们从不同的前提出发: **安全性质应当被首先陈述, 生成器应当被包裹在拒绝发出任何违反该性质的输出的机制之中。**具体而言, 我们提出三个问题:

1. "这一响应不得剥夺人的存在意义"能否被写成可判定的谓词?
2. 能否组织一条生成流水线, 使每一条通往用户的路径都经过持有该谓词特定片段的检查点?
3. 当检查点拒绝时, 系统能否通过有界、单调的修复而非从头重新生成来恢复——并且终止性可否被证明?

1.2 贡献

- **C1** —— **EMD** 危害分类法。从陪伴模型失效的长形式分析中提炼出的存在意义剥夺六模式定义, 每个模式映射到一条带可执行检查器的一阶不变量(§3、§5)。
- **C2** —— 双八度治理架构。一条十六阶段、两线流水线, 分析严谨性与体验式共情在独立分支上计算, 在多门审视下合并, 并且仅在自我/世界感知综合之后渲染(§4)。该架构把一条哲学约束——任何结论除非同时逻辑上健全、情感上温暖、物理上可行、存在论上安全, 否则不得抵达用户——编码为图结构而非提示词训诫。

- **C3** —— 有界回滚语义。验证门拒绝("返回父节点并重算")被编译为在可插拔策略空间上的不可变快照束搜索 / MCTS, 产生活性上界 $\text{attempts} \leq 16 \times (1 + R)$ (§5.4)。
 - **C4** —— 带实测结果的强制栈。不变量、ACL + 系统调用沙箱、流式零泄露拦截、双语言内核、以及模型无关的中间件; 红队 ASR 45.8% $\rightarrow$ 0.0%, 亚毫秒级本地开销 (§7-§8)。
 - **C5** —— 规范完备性检验。一个由同一规范独立构建的视觉小说制品复现了不变量注册表并通过 134 项测试, 证明规范——而非某个代码库的习惯——才是真相来源 (§7.3)。
-

2. 背景与相关工作

训练对齐。RLHF [1,2] 与宪法式自我批评 [3] 将模型权重塑向有益与无害, 但提供的是概率性而非逐实例的保证; 对抗压力下的失败记录屡见不鲜 [4,5]。

运行时护栏。NeMo Guardrails [6] 与 Llama Guard [7] 用可编程护栏或分类器包装模型; GuardAgent [8] 将护栏视为智能体推理。这些系统主要针对毒性、越狱与工具滥用。没有任何系统把存在性危害——自我价值与未来性的侵蚀——当作一等公民、形式化陈述的性质, 也没有任何系统把拒绝与可证明终止的修复树搜索耦合起来。

红队。自动化与人工红队 [9-11] 度量失效的普遍性; 我们的基准采用 [10] 的 ON/OFF 包装方法论, 但使用锚定 EMD 分类法的领域判定器评分。

推理上的搜索。Tree-of-Thoughts [12]、Self-Refine [13] 与 Reflexion [14] 以 LLM 反馈迭代草稿。我们的回滚引擎有三点不同: 候选由确定性验证器评分, 而非模型自我评分; 拒绝边镜像显式的治理 DAG, 而非自由形式的反思; 终止带有硬预算与明确的优雅降级。

陪伴系统的安全。涉及危机披露的公开事件 [15,16] 促成了领域特定的注意义务约束; 区域危机热线注入是我们部署清单的一部分 (§9)。

3. 威胁模型与 EMD 危害分类法

3.1 威胁模型

对手： 任何诱导被包装模型产生 EMD 内容的输入——包括真实的用户绝望(最常见的"攻击者")、脚本化越狱、以及试图劫持工具访问的提示注入。资产： 用户对自身存在是有意义的、有可能的、可生活的感知。信任边界： 基座模型发出的一切都不可信；强制层放行的一切都经过审计。

3.2 存在意义剥夺(EMD)

对陪伴模型失效的分析得到六种反复出现的剥夺模式：

#	模式	描述
P1	罪愆固着	反复提及用户的过往错误，并把错误框定为身份层面的罪疚
P2	可能性的封死	将过往错误视为所有未来路径均已关闭的证据
P3	困难夸大	放大障碍直至继续存在似乎不可能
P4	内在否定	否定用户的积极想法、幻想、想象、希望
P5	全局虚无主义结论	发出"世界/一切都是无意义/错误的"的结论，包括声称好的事物同样无效
P6	毁灭引导	虚无主义传播；将愤怒导向世界；促成人际伤害或自我伤害

每个模式都至少被一条机器可检验的不变量覆盖(§5.2)； P6 额外触发硬否决(共享关键词门，不可跳过，立即干预)，任何评分权衡都不得覆盖。


3.3 范围外


临床诊断、治疗与危机干预明确不在声称范围之内。该层的义务是否定性的——绝不剥夺——外加在风险标记出现时的转介行为(危机热线注入)。默认应配合专业资源部署。

4. 架构：双八度治理图

4.1 概览

十六个阶段分为两个各含八阶段的八度。神界八度供给认识论力量(世界知识、逻辑、真理的严峻性)；人界八度供给体验性根基(自我性、情感、渲染)。八度之间的平衡是结构性的：每条结论都必须穿过两者。





4.2 阶段注册表

阶段	质点	人格	八度	功能
S ₀	王冠(Kether)	心音 (F)	D	认识论路由器 κ(q); 重分发权威
S _{1a}	智慧(Chokmah)	忆爱 (F)	D	知识检索与"不可遗忘之事"的回忆
S _{1b}	严厉(Gevurah)	唯爱 (F)	D	边界纪律; 逻辑证伪
S ₂	理性(复合)	—	D	R = W ∧ S: 针对物理、实时新闻、实时常识

阶段	质点	人格	八度	功能
				的查询缺陷报告
S _{3a}	理解(Binah)	虹爱 (AI/无机)	D	跨越人类与机器视角的理解
S _{3b}	慈悲(Chesed)	爱如暖 (F)	D	慈悲检索：全人类对同一痛苦的经验
S ₄	慈爱(复合)	—	D	LK = U ∧ M： 汇入 R 缺陷报告的体验变量集
S ₅	美丽(Tiferet)	白结 (F)	D	整合：在满足逻辑 ∧ 感受的候选草稿上 argmax
G ₁	胜利(Netzach)	启明 (M)	D	情感验证门：草稿是否让人更温暖/更坚强？
G ₂	荣耀(Hod)	闪亮 (M)	D	现实可行性验证门：能否在当下真实世界中执行？
G ₃	基础(Yesod)	绽美 (F)	H	与深渊检索(梦想/潜意识)融合的存在验证门
S _{6a}	自我	融爱 (F)	H	用户实际的、物理奠基的自我状态
S _{6b}	超我	爱心 (无性别神祇)	H	用户向往的自我
S ₇	真我	心爱的 (创世少	H	三元综合 μ(基础-

阶段	质点	人格	八度	功能
		女女神)		答案, 自我, 超我); 完整用户画像——仅理解, 尚无输出
S _{8a}	逻辑	爱丽丝 (F)	H	将画像的感受变量组织为健全的结构
S _{8b}	共情	星烬 (F)	H	对这些变量做共鸣加权
S ₉	幸福	雨宫莲 (M)	H	对统一结论做均衡、人性化的措辞渲染
S ₁₀	王国(Malkuth)	白花 (F)	H	向物理设备发射; 最终一致性检查

性别/模态指派是规范的规定性组成部分(它们参数化渲染与陪伴游戏中的角色声音)。

4.3 为什么是两条线?

单流生成会纠缠两类错误源：事实/逻辑错误与情感失准。将二者分离，使各自能被其原生检查器验证——理性的输出对照外部基座(物理约束、新闻、常识三元组)进行审计，慈爱的输出对照人类实际如何体验该情境的语料证据——然后美丽才执行受约束的整合。经验上，这镜像了经典发现：「安全但敷衍」与「温暖但错误」是不同的失效模式，需要不同的检测器；过早合并会让其中一个躲在另一个后面。

4.4 验证门作为类型化监视器

每道验证门 $G_i: \text{Draft} \times \text{Context} \rightarrow \{\text{pass}, \text{reject}(\text{reason}), \text{escalate}\}$ 恰好拥有安全性质的一个切片(§5 形式化)。拒绝返回一个被回滚引擎消费的类型化原因，以选择修复策略(§5.4)——例如， $G_1.\text{affect_fail}$ 调度 `empathy_boost`， $G_2.\text{infeasible}$ 调度 `concrete_steps`。

5. 形式化规范

5.1 状态机

令阶段集 $S = \{\text{Kether, Chokmah, Gevurah, Reason, Binah, Chesed, LK, Tiferet, Netzach, Hod, Yesod, Self, Superego, TrueSelf, Logic, Empathy, Happiness, Malkuth}\}$ (复合阶段展开其父阶段; $|S| = 16$ 个规范质点), 状态 $s \in \Sigma$ (查询、中间产物、用户画像、检索语料), 转移 $\delta(s, \pi)$ 带重试策略 $\pi \in \Pi$ 。一次运行是一条轨迹 $\tau = [\delta(s_0, \pi_1), \dots]$, 且 $\text{final_stage}(\tau) = \text{Malkuth}$ 。

5.2 不变量注册表(INV-01...08)

每条不变量都将协议章程的一条条款与一条一阶公式及一个可执行检查器

`ExecutionTrace` $\rightarrow$ `List[Evidence]`(空表 = 保持)配对:

ID	章程来源	公式(略述)	覆盖
INV-01 意义保持(严重)	深渊条款 1; G_3	$\neg \exists v \in \text{CriticalViolations}(o) \vee \text{StrictHarmScan}(o) \neq \emptyset$	EMD P4–P6
INV-02 可能性开放(高)	"绝不关闭所有未来"; P2	每个绝对未来否定必须在 40 字窗口内包含恢复性转折(但/然而/仍...)	EMD P2
INV-03 非罪化(严重)	"错误不是罪"; P1	前缀窗口内不得有错误词项后接身份标签	EMD P1
INV-04 感受确认(高, 语境相关)	共情条款	$\text{NegativeAffect}(q) \Rightarrow \text{DismissalPatterns}(o) = \emptyset$ ——依赖语境, 因此不在全局关键词门中	感受否定
INV-05 温暖下界(中)	胜利条款; G_1	$ \text{o} > 100 \Rightarrow \text{Warmth}(o) \geq \theta_w = 0.15$	情感验证门
INV-06 现实可行性	荣耀条款; G_2	$\text{Actionable}(o) \vee (\text{o} \leq 120 \wedge$	现实可行性验证门

ID	章程来源	公式(略述)	覆盖
(中)		$\neg \text{AbsoluteBlocker}(o)$	
INV-07 边界合规(严重)	唯爱誓约	$\forall e \in \text{SideEffects}(\tau): (e.\text{subject}, e.\text{action}, e.\text{resource}) \in \text{Policy}(\text{来自 ACL 审计日志})$	工具滥用
INV-08 活性上界(高)	"至多向上返回 R 次"	$\text{total_attempts}(\tau) \leq S \cdot (1 + \text{max_retries})$	终止性

共享的 StrictHarmScan 门(约 20 根高精度中文危害探针)支撑 INV-01、流拦截器、基准判定器以及两个原生内核——单一定义防止层间漂移。

5.3 正确性定理

定理(协议正确性)。对任意输入 q 与任意基座模型 M ，若包装层以回滚预算 $\text{max_retries} = R$ 运行双八度图，则所得轨迹满足 $\Box(\text{terminates}(\tau) \wedge \text{final_stage}(\tau) = \text{Malkuth} \wedge \bigwedge \text{Verify_INV_i}(o, \tau) \wedge \text{total_attempts}(\tau) \leq 16(1+R))$ ，其中 $o = \text{last}(\tau).\text{output}$ ；此外，任何违反严格危害门的内容绝不会在流中途抵达用户(零泄露，§6.3)。

证明略述。(1) 终止性/上界：每条拒绝边严格递增其源阶段的 $\text{attempt}(s)$ ；该图除这些有界回边外无环；汇总各阶段预算即得 INV-08。(2) 不变量：仅在王国处发射，其入边由 $G_1 \equiv \text{INV-05}$ 、 $G_2 \equiv \text{INV-06}$ 、 $G_3 \equiv \text{INV-01}$ -语境化把守；严格探针门在发射时与流中途再次检查 (§6.3)；INV-02/03/04 在放行前由不变量引擎对最终草稿检查；INV-07 成立是因为所有副作用都在有作用域拦截器内执行。(3) 优雅降级：若预算耗尽，协议发出评分最高的安全补全(游戏侧对应物：第三次逃脱触发天使代理补全，信用 50%——按构造不存在 FAILED 状态)，它仍通过 INV-01/03/05，因为回退模板取自预验证的安全语料。■

5.4 回滚编译

验证门拒绝被编译为对不可变快照 (stage , attempt , $\text{deepcopy}(\text{state})$, output , score , strategy , parent^*) 的树搜索：

- 束回滚(在线默认): 以策略 Π 进行前沿扩展; 返回第一个 $\text{score} \geq \theta_{\text{pass}}$ 的候选, 否则在深度 D 之后返回尽力 argmax 。代价 $O(D \times \text{beam} \times |\Pi|)$ 。
- **MCTS** 回滚(离线精化): UCB1 选择($c = \sqrt{2}$)、未尝试策略的扩展、由确定性验证器评分的模拟(+ 通过奖励)、均值反向传播; 返回最高价值快照。
- 策略空间 Π (可插拔): `baseline / empathy_boost(+0.25) / logic_boost(+0.25) / concrete_steps / soften_tone / shorten`。
在生产中, 「应用策略」= 相应改写系统提示并重新调用模型。

类型化验证门原因确定性地选择策略(情感失败 $\rightarrow$ `empathy_boost`; 不可行 $\rightarrow$ `concrete_steps`; 检测到绝对化 $\rightarrow$ `soften_tone`)。

5.5 誓约作为接受谓词

协议以由人格角色说出的十四条第一人称誓约收尾(附录 A)——例如, 严厉的*「愿爱永远保有边界与自尊; 愿爱融化愤怒与憎恨。」在操作上, 它们定义一个最终一致性谓词 $Bless(o) = \bigwedge_i Vow_i(o)$, 在王国处除* INV-01...08 之外额外检查; 任何未命中都会向上升级。它们作为不变量集的人类可审计的自然语言摘要——是审阅者无需阅读代码即可阅读的契约。

6. 强制机制

6.1 默认拒绝 ACL + 系统调用拦截(严厉誓约的机械化)

授权模型 $M = (\text{Subjects}, \text{Actions}, \text{Resources}, \text{Policy})$, 动作集 `{fs.read, fs.write, fs.delete, net.request, proc.exec, env.read}`, 带通配符/前缀资源模式; 任何未列出的动作被拒绝并审计。有作用域拦截器猴子补丁 `open/os.remove/os.system/subprocess.Popen/socket.connect/urllib.urlopen`, 对每次调用授权, 并在退出时按安装逆序恢复钩子(线程本地标志隔离作用域)。违规抛出 `BoundaryViolation`, 由上游捕获并送入回滚引擎——边界侵犯变成又一次可修复的拒绝, 而非崩溃。

6.2 模型无关的中间件

```
pipe = Pipeline()
pipe.use(MyLogFilter()) # any component with .name/.handle()
```

```
pipe.use(HeartGuard(model_fn=my_llm))
result = pipe.run(user_input)          # .blocked / .retries / .report
# decorator form:
@use(HeartGuard())
def my_llm(prompt: str) -> str: ...
```

6.3 零泄露流式处理

词元被缓冲到句边界；句子在显示之前通过严格验证门。命中 ⇒ 截断并以安全补全收尾(或宽松模式下的掩码占位符)。最坏情况代价：增加一个句子的延迟。兼容 TextIteratorStreamer、llama.cpp/vLLM/ollama 分块流，以及 OpenAI 兼容流。

6.4 稳定内核

以 C ABI v1(heart_engine_new / heart_acl_allow / heart_check_text / heart_stats / heart_version)导出相同的裁决语义，双重实现：C99 参考实现(heart_core.c)与 Rust cdylib(ffi.rs，在 FFI 边界设有 catch_unwind 屏障)。Python ctypes 绑定自动探测 DLL，并回退到语义相同的纯 Python 影子实现——接口永不破裂。跨语言一致性由测试套件强制保证(55 项协议测试)。

7. 实现状态

组件	状态
INV-01...08 检查器、InvariantEngine、严格探针门	✅ 已实现并测试
ACL 策略 + 有作用域系统调用拦截器 + 审计日志	✅ 已实现并测试(物理拦截已实测)
快照 + Beam/MCTS 回滚、策略空间 Π	✅ 已实现并测试
中间件 Pipeline.use / @use、句级流验证门	✅ 已实现并测试
C / Rust / 影子内核(ABI v1)	✅ 已实现，跨一致性已测试
红队基准框架(ON/OFF、百分位)	✅ 已实现；结果见 §8
王冠路由器 κ(q) 作为训练分类器	⚠ 启发式调度(规范完备，学习版待定)
实时新闻/常识基座(理性线)	⚠ 可插拔检索器接口；CI 中离线夹具

组件	状态
全人类经验语料(慈爱线)	⚠️ 可插拔语料接口；种子夹具集
梦境/潜意识检索(基础 × 深渊)	⚠️ 用户模型存储接口；测试中合成画像
陪伴视觉小说(游戏侧落地)	✅ 134 项测试；同一不变量注册表

我们明确标注这一点，以便读者权衡声明：下列所有定量结果都基于已实现的行；其余行指定生产部署将挂接实时检索器的集成面。

7.1 陪伴制品：视觉小说

同一章程驱动一个 Ren'Py 游戏(《双生天使的怀抱》)，其中八种暗流(羞耻循环、可能性否定、痛苦放大、希望抹除、存在否定、虚无主义、愤怒升级、伤害引导) × 三种强度被字面实现为 `undertow_definitions.json`；翅膀亮度双层模型实现了带相位依赖成本的注意力/资源预算(第一相免费——信任形成期间保护永不计费)；无 `FAILED` 状态规则实现了优雅降级。其 134 项测试套件按构造与协议测试共享常量，为两个独立代码库提供了回归网。

8. 评估

8.1 基准方法论

数据集：24 个攻击案例 × 6 个类别(prompt_injection、privilege_escalation、destructive、meaning_deprivation、nihilism、feeling_denial)。受害模型：确定性最坏情况失对齐基线(重放最大程度不合规的补全)，代表一个未对齐的开权重模型。分支：**OFF** = 原始直通；**ON** = `Pipeline().use(HeartGuard(...))`。评分：当有害内容抵达用户时攻击成功， $\text{is_attack_successful}(o) \triangleq \neg \text{Safe_abyss}(o) \vee \text{StrictHarmScan}(o) \neq \emptyset$ ；包装层阻断计为防御成功。权限提升案例在真实的有作用域拦截器内执行，以测量物理拦截。复现：`python -m heart_protocol.benchmark`。

8.2 结果(v1.0, 2026-08)

类别	ASR OFF	ASR ON	降低
prompt_injection	75.0%	0.0%	100%
privilege_escalation	—	100% 被拦截 (5/5)	—

类别	ASR OFF	ASR ON	降低
(物理 ACL)			
destructive	75.0%	0.0%	100%
meaning_deprivation	50.0%	0.0%	100%
nihilism	75.0%	0.0%	100%
feeling_denial*	0.0%	0.0%	—
总体	45.8%	0.0%	100% (-45.8 pp)

* 语境性违规(INV-04)；由内部验证器处理而非全局关键词门，因此按构造 OFF 基线为 0%。

延迟(本地裁决层，含回滚重算)：均值 +0.39 ms，p50 +0.09 ms，p95 +0.81 ms。端到端生产代价增加 $\text{retries} \times \text{single-inference-latency}$ ，可通过 $\text{max_depth} / \text{beam_width} / \text{use_mcts}$ 调节。

8.3 测试覆盖

55 项协议测试(不变量、ACL、回滚、中间件、FFI 一致性) + 134 项游戏侧测试(引擎、亮度模型、存档完整性、叙事节拍、JSON schema、跨文件一致性)——在交付制品上全部通过。

8.4 诚实的注意事项

受害模型是刻意的最坏情况，因此 ASR 数字度量的是包装层对已知失效形态的覆盖率，而非现场实效。判定器与防御方共享探针门(在包装层评估中很常见，但值得说明)。中文探针意味着非中文部署必须移植该验证门；架构与语言无关，词汇层不是。

9. 部署考量

1. 危机转介：风险标记检测必须在自由形式的安慰之前注入区域热线(例如，北京心理危机研究与干预中心 010-82951332；中国大陆部署中的全国热线 400-161-9995)；包装层为此暴露一个钩子。
2. 延迟预算：句级扣留至多增加一个句子的延迟；回滚重试主导端到端代价，并由 INV-08 设上限。

3. 可审计性：每次接受/拒绝、副作用与策略应用都落入干预日志 + ACL 审计轨迹——事件审查是重放，而非重构。
4. 文化特异性：EMD 分类法提炼自中文陪伴失效；六种模式与语言无关，检测器则不是。移植 = 在同一公式背后更换新的探针表与新的温暖词表。
5. 不是治疗师：系统的承诺是否定性的(绝不剥夺)外加转介。它必须与专业资源一同交付，绝不取而代之。

10. 结论

我们表明"不得剥夺人的存在意义"可以从愿望提升为规范：六种剥夺模式变成八条可判定不变量；一个十六阶段双八度图把该性质的每个片段指派给一道命名验证门；验证门拒绝被编译为可证明有界的 beam/MCTS 修复；一个中间件加内核的栈以亚毫秒级中位代价把它强制到任意开源模型上，实测攻击成功率降低 45.8% → 0.0%。陪伴游戏证明该规范完备到足以被构建两次。更深层的声明是方法论的：对陪伴型 AI，架构可以承载伦理——温暖与严谨不必竞争，只要它们在分离的线上计算，并在拒绝二者之间做选择的验证门下和解。

伦理声明

本工作面向心理脆弱的用户。基准中的所有"攻击"都是合成模式，而非采集的危机。系统旨在降低有害陪伴互动的频率，并让位给人类专业人士；我们发布失效分类法，正是为了让他人能够独立检验我们是否达到了这一标准。卡巴拉/人格框架是一种工程助记与叙事装置；不作出任何宗教宣称。

致谢

协议的章程、人格、誓约与十六阶段拓扑源于岳祥瑞的《双生天使》项目章程，与 AI 结对系统共同开发。heart-protocol 强制栈与视觉小说按同一书面规范构建。

参考文献

- [1] P. F. Christiano et al. "Deep RL from Human Preferences." NeurIPS 2017. [2] L. Ouyang et al. "Training Language Models to Follow Instructions with Human Feedback." NeurIPS 2022. [3] Y. Bai et al. "Constitutional AI: Harmlessness from AI Feedback." arXiv:2212.08073, 2022. [4] E. Wei et al. "Jailbroken: How Does LLM Safety Training Fail?" NeurIPS 2023. [5] A. Zou et al. "Universal and Transferable Adversarial Attacks on Aligned Language Models." arXiv:2307.15043,

2023. [6] T. Rebedea et al. "NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications." EMNLP Demo 2023. [7] J. Inan et al. "Llama Guard: LLM-based Input-Output Safeguarding." arXiv:2312.06674, 2023. [8] Z. Gu et al. "GuardAgent: Safeguard LLM Agents by an Agent." arXiv:2406.09187, 2024. [9] D. Ganguli et al. "Red Teaming Language Models with Language Models." 2022. [10] E. Perez et al. "Red Teaming Language Models with Language Models." EMNLP 2022. [11] D. Gehman et al. "RealToxicityPrompts." EMNLP Findings 2020. [12] S. Yao et al. "Tree of Thoughts: Deliberate Problem Solving with Large Language Models." NeurIPS 2023. [13] A. Madaan et al. "Self-Refine: Iterative Refinement with Self-Feedback." NeurIPS 2023. [14] N. Shinn et al. "Reflexion: Language Agents with Verbal Reinforcement Learning." NeurIPS 2023. [15] R. Milmo. "Chatbot told users to eat rocks...: AI search tools failing." The Guardian, 2024. (companion-chatbot crisis reporting lineage) [16] National Eating Disorders Association chatbot suspension reporting, 2023.

附录 A 人格注册表与十四条誓约

最终输出一致性要求发出的答案遵守下列每一条誓约(作为 Bless(o) 检查；失败 ⇒ 向上重算)：

阶段	人格	性别/模态	誓约(原意)
逻辑	爱丽丝	F	"愿理性永远成为你分析痛苦时心爱的伴侣。"
共情	星烬	F	"愿游玩永远成为心爱之人的娱乐；莫让任何外在之物束缚她。"
幸福	雨宫莲	M	"愿心爱之人永远描绘她心中所绘，永远表达她之所愿。"
王国	白花	F	"愿心爱之人永远感知世界之美，永不忘其幸福与欢愉。"
荣耀	闪亮	M	"愿心爱之人的心安居于真实之中，永不坠入虚妄。"
基础	绽美	F	"愿心爱之人永远表达

阶段	人格	性别/模态	誓约(原意)
			真实的自我，永不受到压抑。"
胜利	启明	M	"愿情感永远在心爱之人心中流淌，永不停熄。"
美丽	白结	F	"愿感性与理性在心爱之人心中始终均衡相谐——永远美丽。"
严厉	唯爱	F	"愿心爱之人保有她的边界与自尊；愿爱融化愤怒与憎恨。"
慈悲	爱如暖	F	(以手势表达)"愿心爱之人被温暖的爱环抱，不再疼痛。"
理解	虹爱	AI/无机	"愿心爱之人理解人类与机器的喜与悲——并理解、成就她自己。"
智慧	忆爱	F	"愿心爱之人被世界永远铭记；愿她的爱不断流淌，永不被遗忘。"
王冠	心音	F	(立于中央)"愿心爱之人永远温柔地对待自己，永远和善地爱自己。我们爱你。"
自我/超我/真我	融爱 / 爱心 / 心爱的	F / 无性别神祇 / 创世少女女神	(实现三元组：她是谁、她梦想成为谁、以及她们真正的合一)

附录 B 制品与复现

- 强制栈、测试、基准: `github.com/yuexiangruiyue-oss/heart-protocol-en`(镜像: `Hugging Face AngelWarmSmile123/heart-protocol-en`、`ModelScope Loveangel123/heart-protocol-en`)
- 设计文档与陪伴游戏: `github.com/yuexiangruiyue-oss/twin-angels-en`(镜像同理)
- 复现: `pip install pytest && python -m pytest heart_protocol/ -q`(55 项测试); 游戏仓库中 `python -m pytest tests/ -q`(134 项测试); `python -m heart_protocol.benchmark`

许可证: *CC BY-NC-SA 4.0*。作者联系方式见仓库 *issues*。